AI 会话项目
测试与修复报告

应用侧缺陷逐项修复与复测；真实任务、数值正确性和供应商能力分别验收。

生成时间 2026-11-04 09:47:11 UTC+8 · Asia/Shanghai（UTC+8）
当前模型：qwen3.8-flash · Responses API · Python Agents SDK 0.24.0

结论与范围 测试矩阵 真实任务 根因与修复 数值核验 截图 逐工具审计

结论与范围

11
问题已有通过证据

0
待最终复测确认

71
本报告逐项收录工具调用

34
离线内嵌证据截图

当前供应商原生压缩尚未通过真实验收。 输入超过配置阈值时服务仍未返回 compaction。应用已增加诚实状态，并修复收到真实压缩条目后的同任务输入边界。SDK 协议替身通过不能替代供应商支持。

首轮三体与工厂任务均出现运行失败，但已有产物经独立数值校验通过。报告保留首轮失败，续作与恢复单独展示；仍在运行的任务不会标成完成。

证据层级：真实 provider / API / Docker；真实模型原件的独立检查；SDK HTTP 协议 fixture；真实浏览器 + authored API/SSE fixture。浏览器模拟手机视口不等于实体手机。

运行耗时已按服务器 API created_at → 对应终态事件重算；三体视觉修订约 434 秒，原 641.249 秒是测试脚本采集耗时，不作为真实模型任务耗时。实际运行包含沙箱准备、模型调用与工具执行，不能称为纯推理耗时。

用户关心的运行中预览已取得最终生产证据：在三体第5轮仍运行时，新浏览器分别打开CSV、HTML和PNG，三次前后API均为running，均成功加载且无浏览器错误。该检查未新增模型请求。

三体共五轮：首轮超时，随后完成收敛复核、HTML视觉修订、收敛说明更正及最终print静态图。第4轮仅改说明字符串；第5轮直接复用已有数值，原11文件哈希不变，最终PNG三处排版缺陷全部消除。

工厂首轮为 ModelBehaviorError 类失败，但现有记录没有保留触发该异常的完整具体原因；本报告不将其武断归因于 HMR。后续同会话恢复完成，最终真实应用中的筛选、重置、下载及手机布局通过。

HTML 脚本/合法标识保留、CSP DOM 注入与 iframe 布局时机均已修复。真实应用中三体原版/修订版 × 桌面/手机及工厂桌面/手机共6组复验通过；供应商原生压缩仍未返回 compaction，因此能力边界继续明确保留。

最终PNG经第5轮真实模型修订与独立像素边界/哈希核验通过；中间Python错误和版式自检失败未隐藏，最终成功恢复。应用修复均有复测证据，供应商原生压缩仍单独未验证。

测试矩阵

检查	证据类型	结果	范围 / 来源
Python 完整回归	自动化 / 含 SDK 协议替身	通过	217 项通过 `final/pytest.log`
代码规范	静态检查	通过	命令日志有明确成功标记 `final/ruff.log`
前端生产构建	真实构建	通过	命令日志有明确成功标记 `final/build.log`
实时/回放时间线	真实浏览器 + authored fixtures	通过	命令日志有明确成功标记 `final/timeline.log`
文件预览与动态更新	真实浏览器 + authored fixtures	通过	命令日志有明确成功标记 `final/previews.log`

检查	证据类型	结果	范围 / 来源
工具/Markdown 显示	真实浏览器 + authored fixtures	通过	命令日志有明确成功标记 `final/rendering.log`
三体数值独立核验	真实模型文件 + 独立数值求解	通过	44 项检查；CSV 与更小步长 RK4 比对 `three-body/physics-verification.json`
工厂指标独立核验	真实模型文件 + 合成数据独立 oracle	通过	173 / 173 项通过 `factory/oracle-validation.json`
工厂原始 HTML 离线交互	未修改真实模型 HTML + 浏览器离线	通过	KPI、筛选、导出、空状态、桌面/手机布局 `factory/ui-baseline.json`
真实诊断后端	真实 provider + Docker + API	通过	错误补丁 → 失败状态 → 正确补丁 → file/cat；真实 context.status `final/diagnostic-live/checks.json`
真实诊断浏览器	真实 provider / backend，无 fixture	通过	错误状态、超阈值未压缩提示、刷新回放 `final/diagnostic-live/browser-checks.json`
供应商原生压缩	真实 provider	未验证	本次未返回 compaction，未通过真实压缩支持验收 `compaction/live-provider-results.json`

检查	证据类型	结果	范围 / 来源
HTML 预览脚本修复复测	真实模型原件应用预览 + 浏览器安全 fixture（分项）	通过	脚本/ID/CSP及布局时机修复通过；真实三体原版/修订版×桌面/手机、工厂桌面/手机共6组通过。 `html-preview/real-artifact-verification.json`; `html-preview/csp-green.log`; `three-body/production-final-interaction-verification.json`
删除文件同步复测	真实历史会话 API + 浏览器 authored fixtures	通过	真实工厂/三体过期文件已从清单移除；实时、历史回放与当前预览同步通过。 `artifact-removal/real-legacy-after.json`; `artifact-removal/frontend/after/artifact-removal.json`
TypeScript 类型检查	静态类型检查，最终命令退出码由主代理确认	通过	最新 typecheck/build/timeline/previews/rendering 联合命令 exit 0；类型检查通过。 `final/typecheck.log`
工厂最终生产构建应用预览	真实模型原件 / 真实应用 / Chromium	通过	3脚本执行；8584→975→8584；应用下载内容相同；360px筛选/重置无溢出。 `factory/preview-production-final.json`
三体收敛复核	真实模型生成结果 + 独立 RK4 全步重算	通过	51 项检查通过，三种步长、15个比较状态及原文件哈希独立核对。 `three-body/convergence-verification.json`
三体第4轮文案更正	真实 provider + 原件结构化差异核对	通过	仅 .conclusion.practical_verdict 改变；所有数值原样，不再误将 h/2→h/4 的差值写成 h→h/4。 `three-body/convergence-final/diff-verification.json`
三体最终原件数据与视觉	真实模型原件 / 独立数据核对 / 离	通过	HTML样本与原CSV逐值相同；真实应用与离线桌面/手机通过；最终print版消除3处排版缺陷，旧11文件不变。 `three-body/print-final/print-`

检查	证据类型	结果	范围 / 来源
	线 Chromium		`verification.json; three-body/visual-final/data-verification.json; three-body/production-final-interaction-verification.json`
带属性 head 的 CSP 注入与隔离	真实 Chromium + authored 攻击 fixture	通过	DOM注入和网络前阻断检查通过；无真实外网攻击请求。 `html-preview/csp-green.log`
三体真实应用 canvas 尺寸与画面	真实模型原件 / 真实应用浏览器	通过	真实桌面670×670、手机334×334；RGB轨迹非空，暂停/继续/滑块/重置通过，无人工resize。 `three-body/production-final-interaction-verification.json; three-body/production-final-mobile-interaction-verification.json`
最终成果真实UI链接与下载	真实模型产物 / 真实应用下载	通过	最终CSV、metrics、final HTML、print PNG、convergence_final 5个真实UI链接下载与API字节及元数据一致。 `three-body/print-final-delivery-verification.json`
运行中的真实生产文件预览	真实模型任务仍 running / 真实生产UI / fresh Chromium	通过	CSV0.185s、HTML0.312s、PNG0.157s；每次前后API均running，0页面/控制台错，新增模型请求0。仅为本次3次加载记录，不作性能SLA。 `final/live-preview-final/report.json`
最终服务重载与历史恢复	真实生产构建 / 重启后API与全部文件下载	通过	/health、生产页、两真实会话与global/files均200；22个当前文件下载均200且size核对，过期2 IDs未复活。 `final/post-restart.json`
真实 Docker 原生 SDK 冒烟	真实 Docker + 原生	通过	四组 PASS：原生 exec/patch/file/image/Skills 与隔离/HTTPS；持久化/刷新/清理；PTY 取消；聚合配额。file/time 已补齐，模型管道命令可靠性限制

检查	证据类型	结果	范围 / 来源
	Agents SDK 工具		仍保留。 environment/docker-sdk-smoke-final.log

真实复杂任务与续作

场景	运行终态	服务器运行时间 / 实际耗时	测试脚本耗时	事件与工具	终态错误
三体任务·首轮	未通过	2026-11-04 08:45:45 UTC+8 → 2026-11-04 09:00:57 UTC+8 **911.921 秒** API run.created_at → 终态事件时间	912.149 秒 可能含轮询、截图和采集延迟	238 事件 / 25 工具 c91dc208 919b4712 ba8382b6 5730df4d	任务执行超时，请缩小任务范围后重试。
三体任务·同会话续作	运行完成	2026-11-04 09:03:59 UTC+8 → 2026-11-04 09:07:24 UTC+8 **204.555 秒** API run.created_at → 终态事件时间	251.006 秒 可能含轮询、截图和采集延迟	488 事件 / 6 工具 67800637 2e99420e 921a29c3 8c601537	无；逐工具失败见下方审计
三体任务·视觉最终修订	运行完成	2026-11-04 09:10:17 UTC+8 → 2026-11-04 09:17:31 UTC+8 **434.057 秒** API run.created_at → 终态事件时间	641.249 秒 可能含轮询、截图和采集延迟	328 事件 / 4 工具 4c954b1c 65cc4632 adef67fb e076bd58	无；逐工具失败见下方审计
三体任务·收敛说明	运行完成	2026-11-04 09:22:51 UTC+8 → 2026-11-04	60.78 秒 可能含轮	153 事件 / 1 工具 efc56457	无；逐工具失败见下方审计

场景	运行终态	服务器运行时间 / 实际耗时	测试脚本耗时	事件与工具	终态错误
文案更正（第4轮）		09:23:52 UTC+8 **61.299 秒** API run.created_at → 终态事件时间	询、截图和采集延迟	ff5d427c 8ea36e3b 932ba361	
三体任务·静态图最终排版	运行完成	2026-11-04 09:36:00 UTC+8 → 2026-11-04 09:40:11 UTC+8 **251.424 秒** API run.created_at → 终态事件时间	252.041 秒 可能含轮询、截图和采集延迟	234 事件 / 5 工具 bcbeabff 56aa497a be1376b4 566b446d	无；逐工具失败见下方审计
工厂报表·首轮	未通过	2026-11-04 08:45:47 UTC+8 → 2026-11-04 09:00:27 UTC+8 **880.139 秒** API run.created_at → 终态事件时间	880.426 秒 可能含轮询、截图和采集延迟	209 事件 / 23 工具 822c4573 3ce447fc a53dbcae 87f64c82	模型返回了无法执行的工具请求或响应格式。已保留工作空间文件，请重试或调整模型。
工厂报表·同会话恢复	运行完成	2026-11-04 09:04:21 UTC+8 → 2026-11-04 09:06:50 UTC+8 **149.046 秒** run.started 事件时间 → 终态事件时间（未取得 API created_at）	149.982 秒 可能含轮询、截图和采集延迟	548 事件 / 4 工具 32c842db 3ee9480b 9734bdca 7e3e2616	无；逐工具失败见下方审计
真实诊断·压缩状态与补丁恢复	运行完成	2026-11-04 08:54:54 UTC+8 → 2026-11-04 08:55:31 UTC+8 **37.204 秒**	None 秒 可能含轮询、截图和采集延迟	97 事件 / 3 工具 6458c1da 74ce415b ac5777e5 1c93b6e3	无；逐工具失败见下方审计

场景	运行终态	服务器运行时间 / 实际耗时	测试脚本耗时	事件与工具	终态错误
		API run.created_at → 终态事件时间			

实际运行按 API run.created_at 到对应 run 的明确终态事件计算，包含沙箱准备、模型调用及工具执行；缺 API 开始时间时明确使用 run.started 事件。测试脚本耗时独立列示，不作为提供方推理时长。事件序号允许跨 run 的间隔，不能要求连续。

问题、根因、修复与前后复测

01 · 更新中的文件预览长期加载

通过

修复前

运行事件不断更新文件列表时，预览请求反复被取消，用户无法在任务进行中查看文件。

根因

effect 依赖文件修订元数据（size/created_at 等），更新触发请求清理/取消；并发更新时还需回收被移除的 sheet/page 选择。

修复

按稳定文件身份管理请求，内容更新后追赶最新修订；只在关闭/换文件时取消；数据缩小时重置分页和工作表选择。

复测与最终结果

动态更新fixture覆盖17次修订和缩表分页复位；最终又在真实三体第5轮仍running时用fresh browser打开CSV/HTML/PNG，分别0.185/0.312/0.157秒加载，三次前后API均running，0页面/控制台错误。检查没有发起新模型请求，直接证明本次生产运行中可预览。

证据: preview/before/preview-live-updates.json
preview/before-pagination-reset/preview-live-updates.json
preview/after/preview-live-updates.json
final/live-preview-final/report.json

02 · 同一任务压缩后仍发送旧工具历史

通过

修复前

新增真实 SDK 协议测试在第三次模型请求发现旧 call_id；原测试只验证新 run，因此漏检。

根因

SDK 0.24 沙箱准备处理 original input，模型循环后拼接本轮新产物，原生边界未覆盖该完整请求。

修复

官方 call_model_input_filter 组合原生 ToolOutputTrimmer 与 Compaction.process_context；只在有真实 compaction 条目时移除旧请求历史。

复测与最终结果

专项 44 项通过，覆盖压缩后两个工具配对、重复压缩、SQLite 重开及 provider 失败恢复；协议替身不算真实供应商支持。

```
证据: compaction/REPORT.md
compaction/regression.log
compaction/full-regression.log
```

03 · 超阈值但没有压缩时缺少可见诊断

通过

修复前

仅收到 compaction 时发成功事件，未压缩时没有输入量与阈值证据。

根因

界面把没有成功事件表现为空白，无法区分未达阈值、供应商未返回与显示缺失。

修复

增加每响应 context.status；显示实际输入 tokens、阈值及真实条目数量；实时/回放同 reducer，子代理独立归属。

复测与最终结果

真实模型/API/浏览器验证准确显示“输入超过阈值，未观测到压缩”，刷新后保持；不把裁剪称为压缩。

证据：final/diagnostic-live/checks.json
final/diagnostic-live/browser-checks.json
compaction-ui/browser-green.log

04 · 当前供应商原生压缩仍未通过验收

未验证

修复前

历史报告使用 glm-5.3；本次环境实际为 qwen3.8-flash，必须重新验证。

根因

四次直接流式请求接受 context_management，但输入超阈值仍未返回 compaction。供应商内部原因未获证实。

修复

保留当前模型和 Responses 协议，增加诚实诊断；未伪造摘要或静默切换服务。

复测与最终结果

真实 qwen3.8-flash 请求在默认 32000 阈值、实际输入 41296 / 41167 tokens 时仍无 compaction 条目。参数被接受、普通事实保留或 SDK 协议测试通过，都不等于真实原生压缩已经生效。保留未通过供应商原生压缩验收的结论。

证据：compaction/live-provider-results.json
compaction/live-runtime-results.json

05 · 原生 apply_patch 失败被展示为普通返回

通过

修复前

缺少 Begin Patch 的输入返回原生错误文本，但原事件缺少失败标记。

根因

SDK 0.24 custom tool 异常分支未经过 RunConfig.tool_error_formatter，不能靠该回调修复。

修复

用官方 Filesystem.configure_tools 包装原生 apply_patch，记录真实异常 call_id 后原样抛出，由 custom_data_extractor传出失败状态。

复测与最终结果

真实 8002 诊断按错误补丁→正确补丁恢复→file/cat 全链路通过；不正则猜测任意输出，也不隐藏原错误。

证据：final/diagnostic-live/checks.json
final/diagnostic-live/browser-checks.json
baseline/patch-status-before.log
baseline/patch-status-after.log

06 · 沙箱缺少 file/time

通过

修复前

真实任务触发 file/time 缺失；部分命令经 tail 管道后仍显示退出 0。

根因

初始镜像缺少基础 file/time 命令。模型将失败命令接入 tail 管道且未启用 pipefail 时，管道会返回尾部命令的 0；这不能要求界面凭 0 自动判断前段失败。

修复

镜像补齐 file/time；提示明确 POSIX/Bash 与 pipefail、补丁 Begin/End/+ 行，以及 write_stdin 必须使用真实 session ID。提示用于降低模型错误概率，不保证永不失败。

复测与最终结果

新版Docker smoke四组PASS，真实诊断file成功，Bash pipefail校验通过。该PASS仅指工具可用性和已验证的执行语义；第5轮模型仍使用未启用pipefail的tee管道，多个Python Traceback被管道0退出码掩盖，模型命令写法没有因此根治。完整审计保留语义失败与后续恢复。

证据: environment/file-command-before.json
environment/file-command-after.log
environment/time-command-before.log
environment/docker-sdk-smoke-final.log
final/diagnostic-live/checks.json

07 · 生成文件删除后保留过期卡片和 404

通过

修复前

工厂验收下载已删除生成物时遇到 404；需要同步持久化清单、事件与已打开预览。

根因

文件扫描/事件链路未完整表达删除，与浏览器现有清单状态不一致。

修复

同步磁盘删除、持久化文件记录、artifact.removed 事件及前端实时/回放状态，当前预览在文件移除时正确关闭或更新。

复测与最终结果

浏览器 fixture 的实时/回放删除场景通过；真实历史工厂与三体会话的过期文件 ID 均从清单消失，会话访问仍为 200。两种证据分别记录，没有把 fixture 当真实模型验证。

证据：`artifact-removal/frontend/before/artifact-removal.json`
`artifact-removal/frontend/after/artifact-removal.json`
`artifact-removal/real-legacy-after.json`

08 · HTML 预览清理误删脚本，报表与动画未初始化

通过

修复前

应用内工厂 KPI 为 —，三体 canvas 不动；同一下载原件离线交互正常。

根因

原预览净化使用跨标签字符串规则，脚本中的标记文本可能导致合法脚本内容被误删；另有合法元素 id 丢失，影响生成页面初始化。

修复

按 DOM 节点处理并保留合法内联脚本及标识，在隔离 iframe 中执行，外部资源与导航限制保持。

复测与最终结果

真实工厂原件的 3 个脚本均保留并执行，真实应用 KPI 随筛选/重置 8584 → 975 → 8584，应用下载按钮获得相同 HTML；360px 手机视口无横向溢出。三体画布尺寸问题独立列为未完成项，不包含在此通过结论中。

证据：`html-preview/diagnostic.json`
`html-preview/identifier-diagnostic.json`
`factory/preview-production-final.json`
`html-preview/previews-regression.log`
`html-preview/build.log`

09 · 三体静态 PNG 的重叠、越框与缺字

通过

修复前

数值验收通过，但首轮 PNG 与手机画面仍存在注释遮挡或裁切，不能把数值正确等同于视觉交付合格。

根因

根代理复检前一版PNG发现底部页脚重叠、右栏越框、E0/L0缺字；数值/HTML通过不能替代静态图最终可读性验收。

修复

第5轮真实模型另存three_body_print.png，直接使用既有CSV/metrics/convergence数据重绘版式，不重新积分、不修改已有文件；ASCII E0/L0、独立footer与右栏边界检查。

复测与最终结果

最终print版2010×1320已通过根代理及独立目视：三处缺陷消除；像素边界测量横轴标题底876px、footer顶1081px，间隔205px；右栏54条文字在框内，E0/L0完整。源文件哈希匹配、11旧文件不变，真实UI5个最终链接下载内容与API一致。第5轮前3个语义失败及第4个中间版式自检失败保留，第5个调用修复后检查全过。

证据：three-body/visual-final/three_body_final.png
three-body/print-final/print-verification.json
three-body/print-final/tool-audit.json
three-body/print-final-delivery-verification.json
three-body/visual-final/data-verification.json
three-body/convergence-final/diff-verification.json
three-body/three-body-result.json

10 · head 带属性时字符串替换漏注入隔离策略

通过

修复前

恢复合法 id 后，review 发现 head 若带属性，原字符串替换可能漏注入 CSP。

根因

恢复合法标识后的 review 发现，原固定 <head> 字符串替换无法覆盖带属性的 head，可能漏注入 CSP。

修复

改为 DOM 插入 CSP 与限制节点，增加带属性 head 等攻击 fixture，检查外部请求在到达网络前被阻止。

复测与最终结果

CSP 攻击 fixture、预览回归及生产构建通过。该结论属于真实 Chromium 上的 authored fixture 隔离测试，不冒充真实供应商能力；未向真实外网发送攻击请求。

证据：`html-preview/csp-red.log`
`html-preview/csp-green.log`
`html-preview/previews-regression.log`
`html-preview/build.log`

11 · 真实三体预览的 canvas 初始尺寸仍可能为 1×1

通过

修复前

恢复脚本及合法标识后，真实应用预览仍出现 canvas 初始 1×1，需要继续检查布局。

根因

React挂载iframe时立即设置srcdoc，生成页面的内联初始化可能早于iframe完成布局，getBoundingClientRect首次读取0，页面将canvas backing store钳为1×1。未证实display:none是原因。

修复

先挂载opaque iframe，由ResizeObserver确认非零尺寸后再加载原srcdoc；保持生成脚本原样，不向脚本注入resize。同步补充已加载HTML刷新生命周期与初始化fixture。

复测与最终结果

真实应用对三体原版/修订版×桌面/手机均通过：桌面670×670、手机334×334，独立检查确认RGB轨迹像素存在，暂停/继续/滑块/重置正确；无人工resize、无page error。旧canvas-timing FAIL保留，已由新的production-final强验收取代。

证据: `html-preview/real-artifact-before-canvas.json`
`html-preview/canvas-red.log`
`html-preview/canvas-green.log`
`html-preview/loaded-frame-regression.log`
`html-preview/real-artifact-verification.json`
`three-body/production-final-interaction-verification.json`
`three-body/production-final-mobile-interaction-verification.json`
`html-preview/overview-verification.json`

12 · 输出目录失效或替换为符号链接时文件同步抛 500

通过

修复前

删除同步修复后的边界 review 发现，reconcile_outputs 遇到失效目录或符号链接可能抛 500。

根因

reconcile_outputs在安全检查前调用会mkdir的workspace()；outputs被悬空symlink或普通文件替代时FileExistsError阻断GET与任务终态处理。

修复

workspace初始化失败时保守跳过文件同步并保留现有元数据，不跟随不可信符号链接、不删除已有记录。

复测与最终结果

先由2项失败回归复现，再经8项相关测试通过；最终完整Python217项、Ruff与git diff --check通过，独立review无未解决P0/P1/P2。

```
证据: artifact-removal/unsafe-directory-before.log
artifact-removal/backend-after.log
artifact-removal/REPORT.md
final/code-review.md
final/pytest.log
final/ruff.log
```

数值与交互验收

三体：独立 Newton 引力 RK4 验证

从下载 CSV 重新计算的指标	结果
sample_count	1266
initial_energy	-1.2871419917663254
max_relative_energy_error	2.1354125338515813e-09

从下载 CSV 重新计算的指标	结果
initial_angular_momentum	0.0
max_absolute_angular_momentum_error	1.9475803192392505e-09
max_center_of_mass_norm	4.714045597952174e-10
minimum_pair_distance_csv_samples	0.690526646322119

独立积分步长 0.0001，比生成器要求小 10 倍；CSV 四舍五入与全精度内部指标分别核验，避免混用误差口径。

▶ 展开全部三体检查与独立误差依据

工厂：合成数据独立 oracle，173 / 173 项通过

原始 HTML 离线浏览器核对覆盖全量 KPI、产线/班次/日期筛选、CSV 导出、空筛选、重置及 390px 布局。原件正确与应用预览正确分别记录。

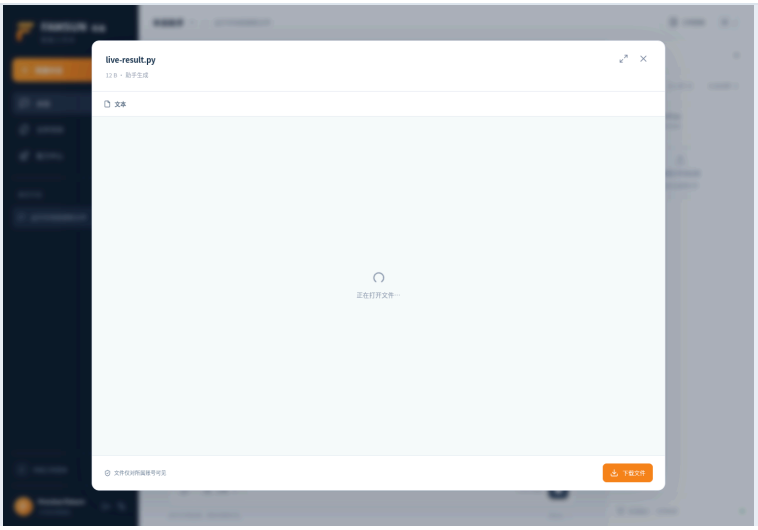
▶ 展开工厂指标与交互检查

真实压缩探针：阈值、用量与实际产物

配置阈值	轮次	实际输入 tokens	compaction 数量	响应状态
1024	1	6526	0	completed
1024	2	6405	0	completed
32000	1	41296	0	completed
32000	2	41167	0	completed

关键问题与最终结果截图

截图原图保持不变。界面内部时间可能为浏览器 UTC；本报告表格统一 UTC+8。点击“查看大图”展开整行读取细节。

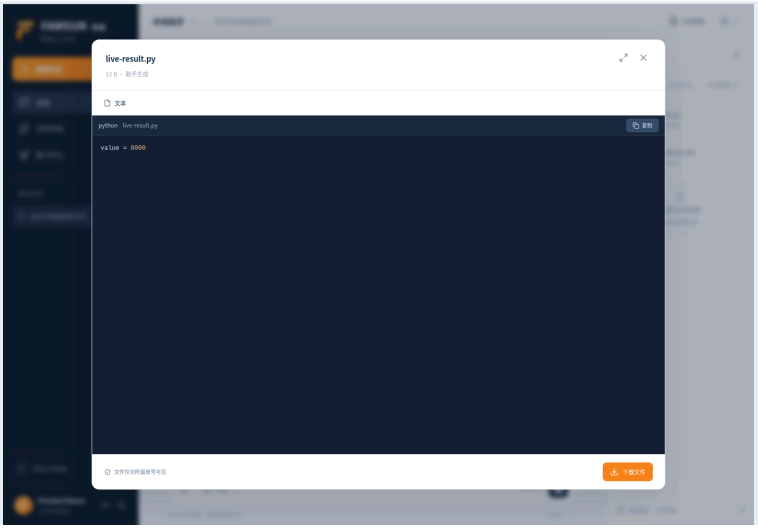


修复前：更新中的预览无法完成加载

浏览器 fixture

`preview/before/preview-failure.png`

▶ 查看大图

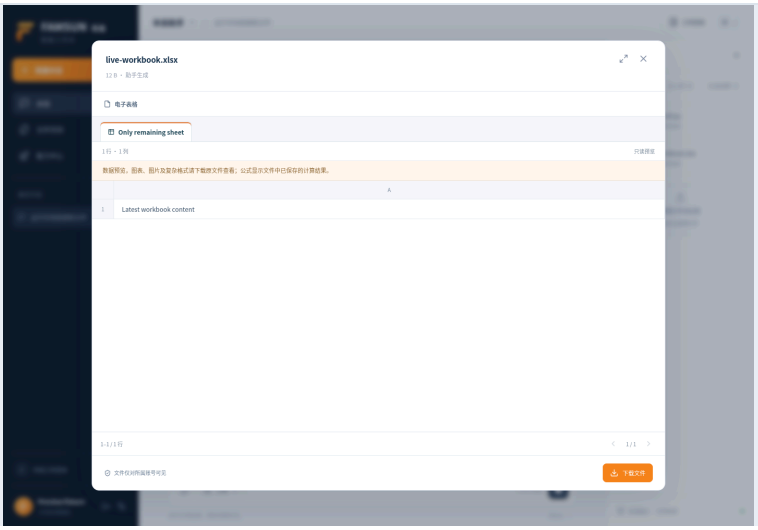


修复后：持续更新期间预览可读

浏览器 fixture

`preview/after/preview-during-updates.png`

▶ 查看大图

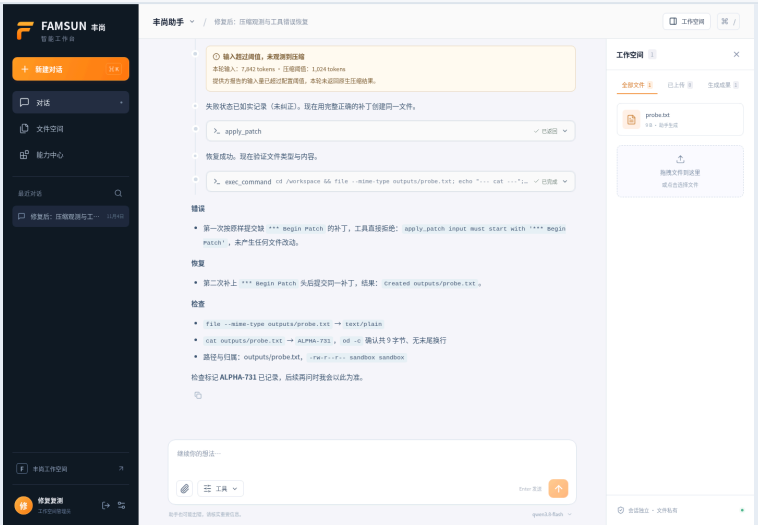


修复后：工作表缩小时分页复位

浏览器 fixture

`preview/after/preview-shrinking-workbook.png`

▶ 查看大图

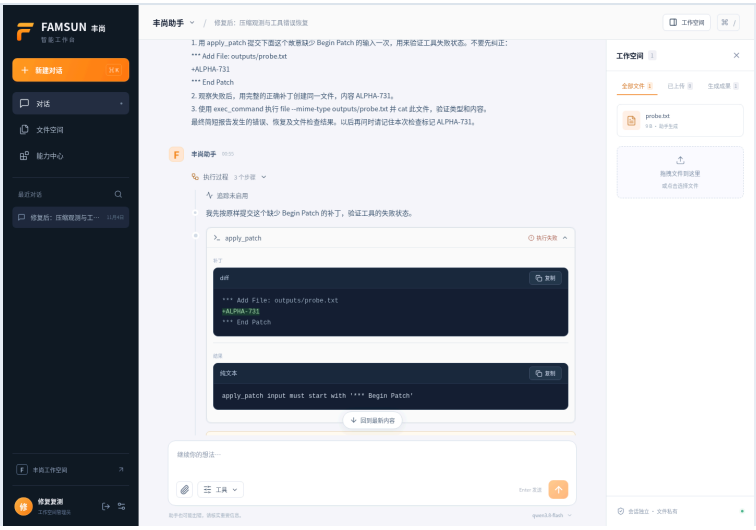


真实模型：超过阈值但未返回原生压缩条目

真实 provider / API / UI

`final/diagnostic-live/real-compaction-status.png`

▶ 查看大图

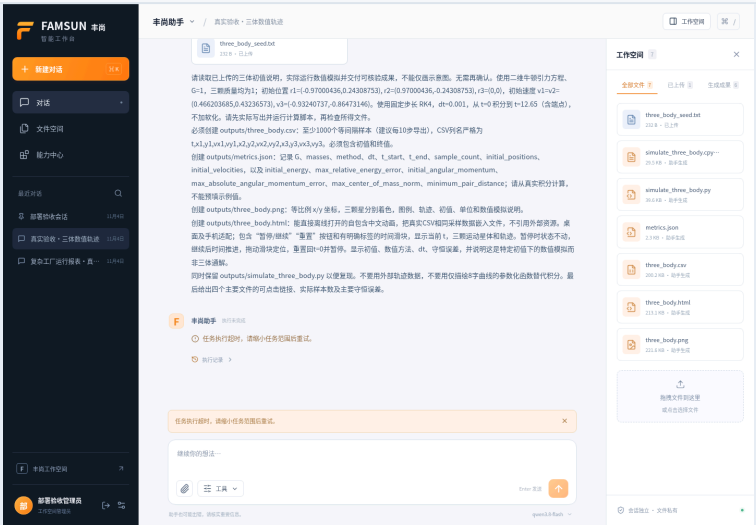


真实模型：补丁失败被正确标记并恢复

真实 provider / API / UI

`final/diagnostic-live/real-patch-failure-fixed.png`

▶ 查看大图

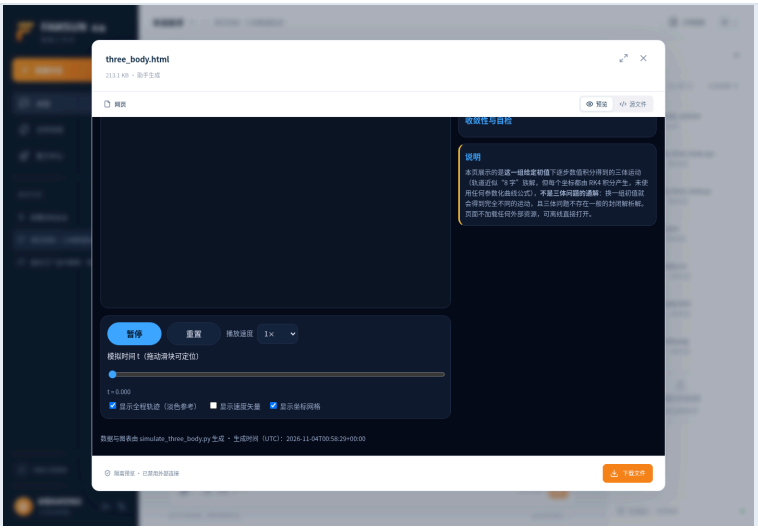


三体首轮：终态失败，不能以文件存在替代成功

真实 provider / UI

`three-body/screenshots/03-final-answer.png`

▶ 查看大图



修复前：应用内三体动画未初始化

真实模型产物 / 应用预览

three-body/screenshots/05-app-html-desktop-failure.png

▶ 查看大图



三体原件：离线暂停、继续、滑块与重置

真实模型原件 / 离线 Chromium

three-body/screenshots/06-offline-desktop-interaction.png

▶ 查看大图

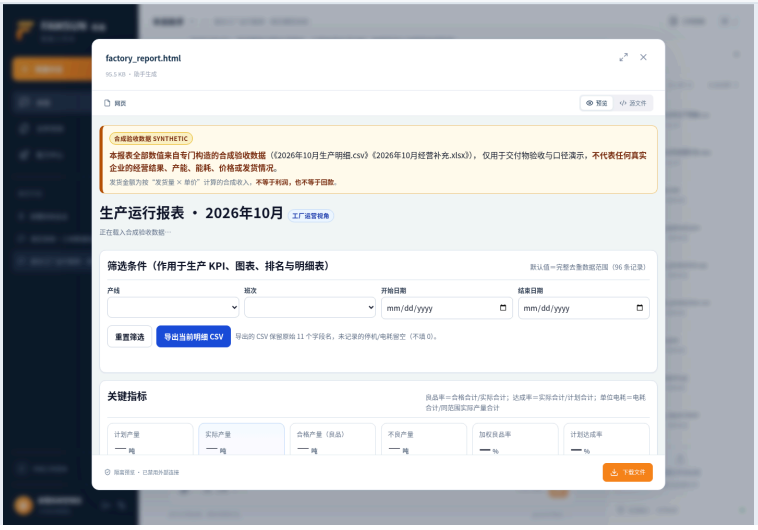


三体原件：390px 浏览器视口交互

浏览器模拟手机视口

three-body/screenshots/06-offline-mobile-interaction.png

▶ 查看大图



修复前：应用内工厂 KPI 未初始化

真实模型产物 / 应用预览

factory/screenshots/app-preview-initialization-failure.png

▶ 查看大图



工厂原件：独立核对后的离线报表

真实模型原件 / 离线 Chromium

`factory/screenshots/baseline-desktop-full.png`

▶ **查看大图**



工厂原件：产线、班次筛选改变 KPI

真实模型原件 / 离线 Chromium

`factory/screenshots/baseline-desktop-filtered.png`

▶ **查看大图**



工厂原件：空筛选不会产生 NaN / Infinity

真实模型原件 / 离线 Chromium

`factory/screenshots/baseline-empty-filter.png`

▶ **查看大图**

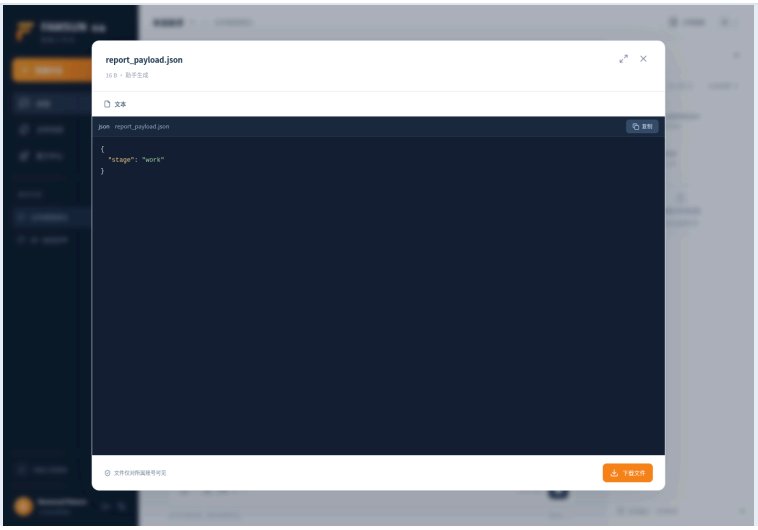


工厂原件：手机视口筛选与布局

浏览器模拟手机视口

`factory/screenshots/baseline-mobile-filtered.png`

▶ **查看大图**

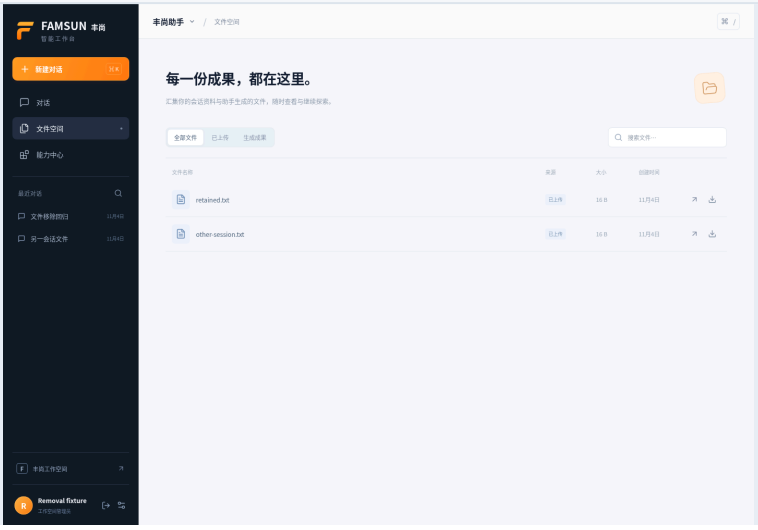


修复前：删除产物清单与预览未同步

浏览器 fixture

`artifact-removal/frontend/before/failure.png`

▶ 查看大图

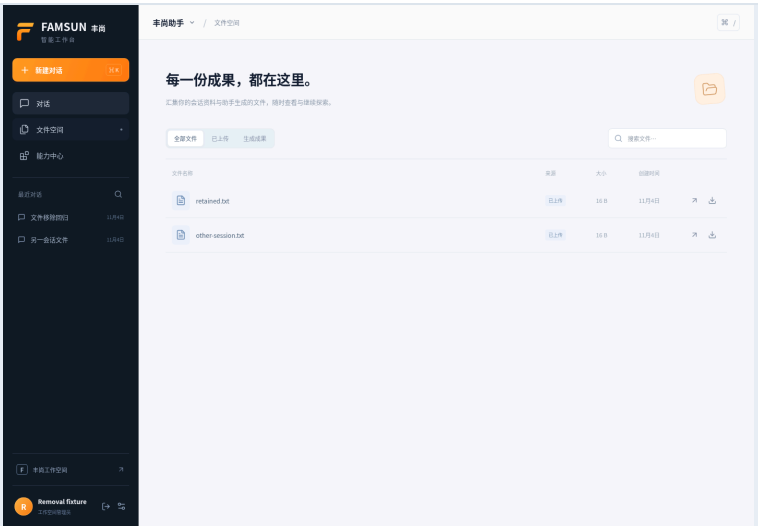


后续复测截图 · removed-global-live

以对应 JSON 记录的测试范围为准

`artifact-removal/frontend/after/removed-global-live.png`

▶ 查看大图

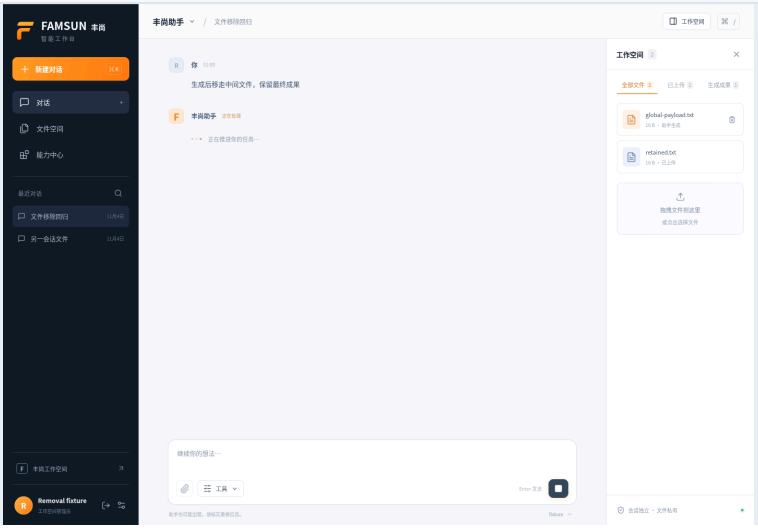


后续复测截图 · removed-history-and-files

以对应 JSON 记录的测试范围为准

`artifact-removal/frontend/after/removed-history-and-files.png`

▶ 查看大图

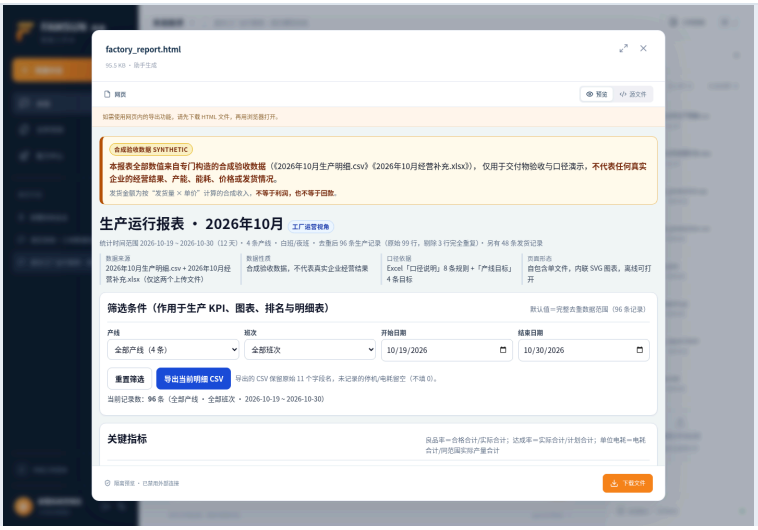


后续复测截图 · removed-live

以对应 JSON 记录的测试范围为准

`artifact-removal/frontend/after/removed-live.png`

▶ 查看大图

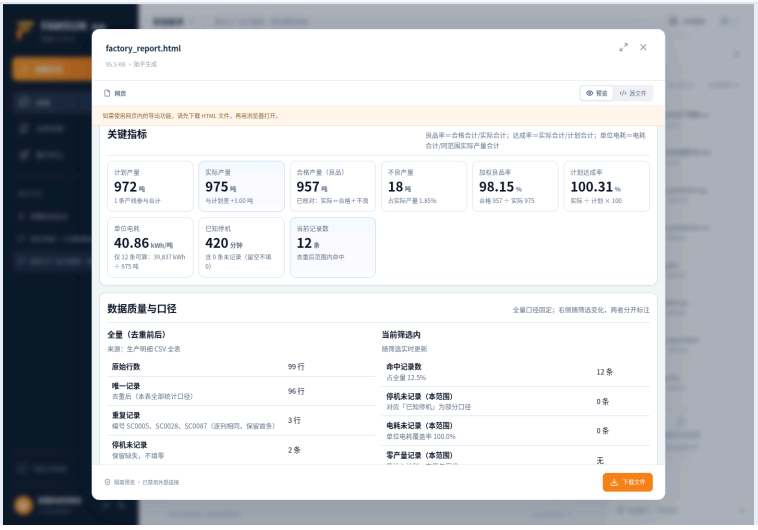


工厂最终应用预览：真实生产构建中 KPI 和脚本初始化正常

真实模型产物 / 真实应用生产构建

`factory/screenshots/production-final-app-preview-desktop.png`

▶ **查看大图**



工厂最终应用预览：筛选改变真实 KPI

真实模型产物 / 真实应用生产构建

`factory/screenshots/production-final-app-preview-filtered.png`

▶ **查看大图**

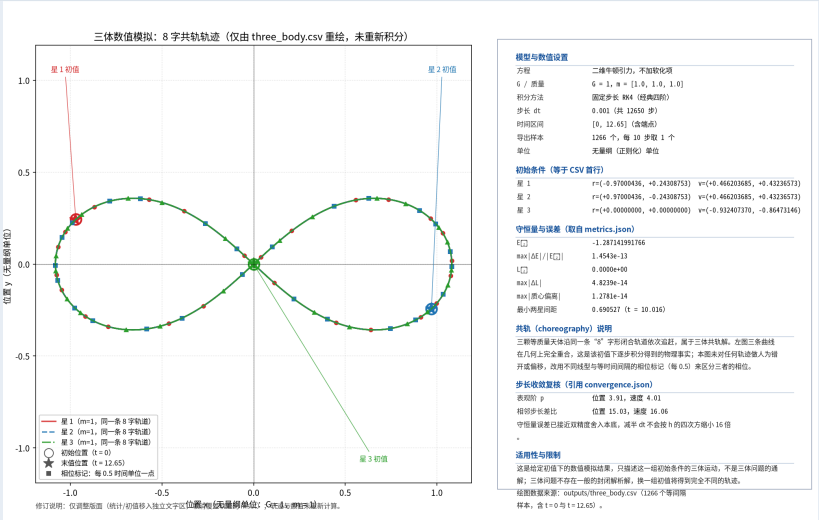


工厂最终应用预览：360px 浏览器视口筛选与布局通过

真实应用 / 浏览器模拟手机视口

`factory/screenshots/production-final-app-preview-mobile-filtered.png`

▶ 查看大图



前一版静态PNG：根代理发现页脚重叠、右栏越框和缺字，保留为修订前证据

真实模型产物 / 静态排版缺陷证据

`three-body/visual-final/three_body_final.png`

▶ 查看大图

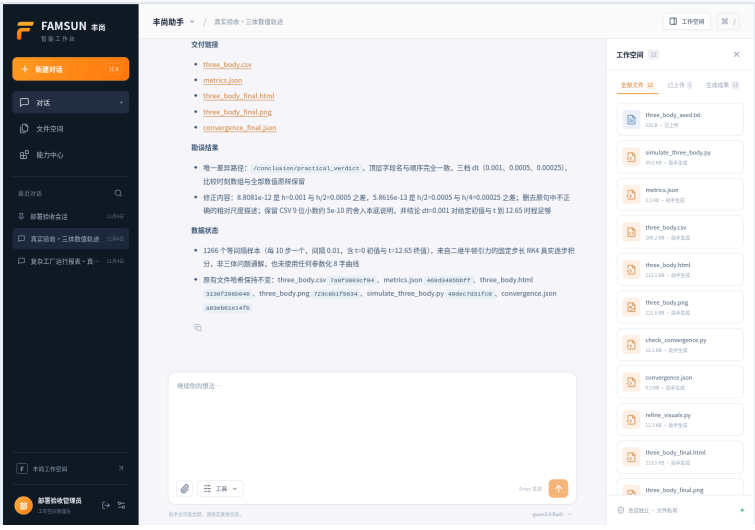


三体最终原件：离线手机视口重置与布局（不代表应用canvas已通过）

真实模型原件 / 离线 Chromium 模拟手机视口

three-body/screenshots/final-06-offline-mobile-reset.png

▶ 查看大图



三体第4轮完成后的最终成果链接

真实 provider 同会话续作 / 应用截图

three-body/screenshots/09-final-links.png

▶ 查看大图

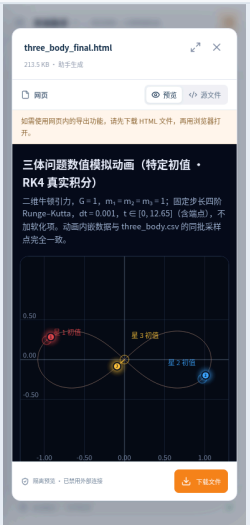


最终真实应用：无需人工resize，首屏即显示三色轨迹与有效画布

真实模型原件 / 生产应用 / Chromium桌面

three-body/screenshots/production-final-05-app-html-desktop-first-view.png

▶ 查看大图



最终真实应用：390px新context中首屏轨迹与画布正常

真实模型原件 / 生产应用 / Chromium模拟手机视口

three-body/screenshots/production-final-mobile-05-app-html-mobile-first-view.png

▶ 查看大图



最终三体原件离线手机视口：重置后状态正确

真实模型原件 / 离线Chromium模拟手机视口

three-body/screenshots/production-final-06-offline-mobile-reset.png

▶ 查看大图

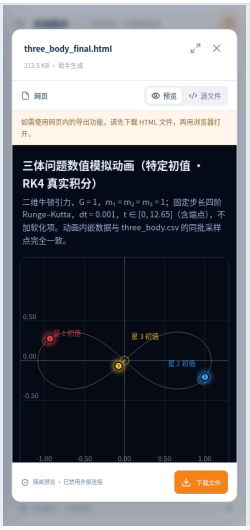


最终修订版真实应用：新context首屏完整轨迹、三颗星均可见

真实模型产物 / 生产应用 / 未手动resize

html-preview/three-body-final-overview-desktop.png

▶ 查看大图

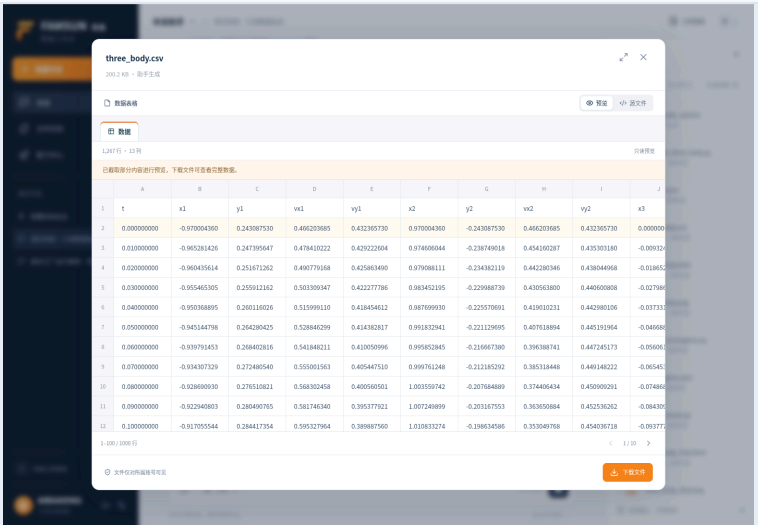


最终修订版真实应用手机首屏：轨迹和初始画面完整可见

真实模型产物 / 生产应用 / 模拟手机视口

`html-preview/three-body-final-overview-mobile.png`

▶ 查看大图



最终真实生产：任务仍运行时CSV已加载，前后API均running

真实任务进行中 / fresh Chromium / 无新模型请求

`final/live-preview-final/01-three_body.csv.png`

▶ 查看大图

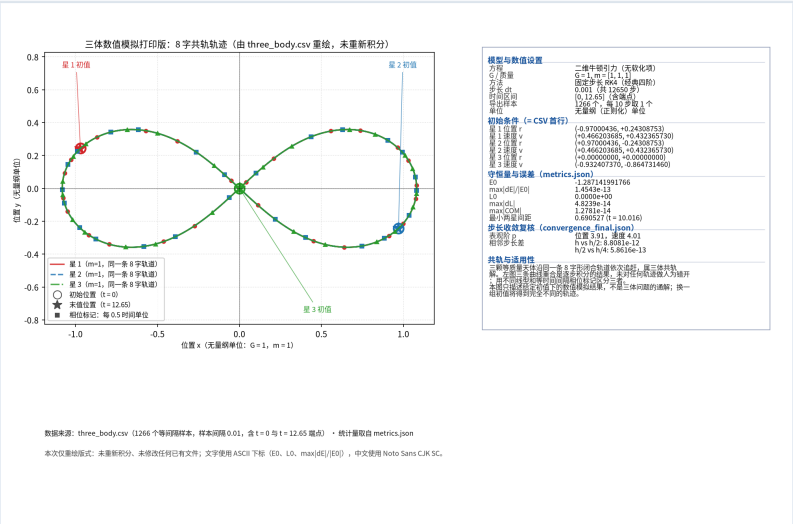


最终真实生产：任务仍运行时HTML预览加载，画布670×670

真实任务进行中 / 真实生产UI / 非fixture

`final/live-preview-final/02-three_body_final.html.png`

▶ **查看大图**



最终print静态图：footer与横轴分离、右栏不越框、E0/L0完整

第5轮真实模型产物 / 独立像素边界与哈希检查通过

`three-body/print-final/three_body_print.png`

▶ **查看大图**

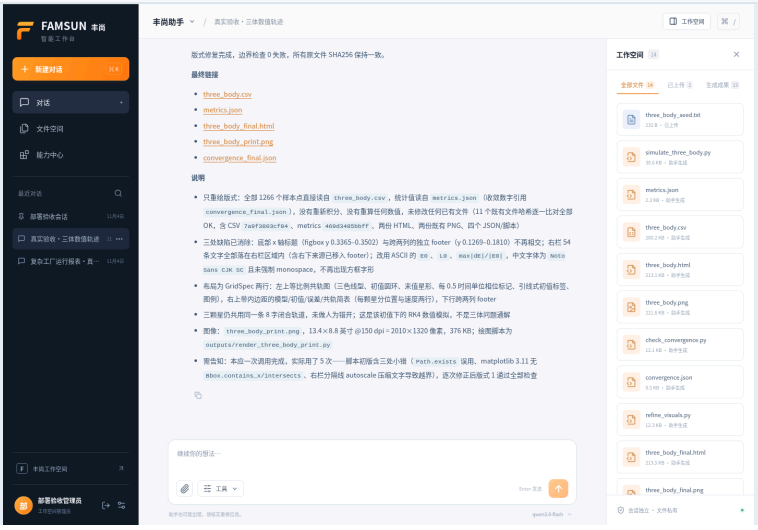


最终真实应用：print PNG预览加载，尺寸2010×1320

真实生产UI / 原图预览与下载一致

three-body/screenshots/print-12-png-preview.png

▶ 查看大图



第5轮真实运行完成后的最终5个成果链接

真实provider与生产UI / 5个下载独立核对通过

three-body/screenshots/print-10-production-final-links.png

▶ 查看大图

每一步工具调用审计

按运行、agent、父调用和 call_id 配对，记录真实参数、输出、时间和终态。工具已返回不代表业务结果正确；管道可能掩盖前段退出码，需结合独立审计与数值核验。完整脱敏内容保存在同目录 results.json

的 runs[].tool_calls。

三体任务·首轮 · 未通过 · 25 次

▶ 01 · exec_command · 已返回 · 1.675 秒 · call_5c02d92d2cd340cab64d8b01

▶ 02 · exec_command · 已返回 · 1.014 秒 · call_0c80e4b5ffee4358b952d26c

▶ 03 · exec_command · 已返回 · 1.478 秒 · call_dde3d10f21c34fda929906bc

▶ 04 · exec_command · 已返回 · 1.003 秒 · call_176f7d6d271a4758a1e8bab6

▶ 05 · update_plan · 已返回 · 0.054 秒 · call_d1a270babd8b4ccd8cd6f6dc

▶ 06 · apply_patch · 未通过 · 0.02 秒 · call_43645fc3d3654b2e91c36781

▶ 07 · apply_patch · 已返回 · 0.846 秒 · call_23946856fe944934ba654539

▶ 08 · apply_patch · 未通过 · 0.197 秒 · call_9c2e6fad26a748388a8eae63

▶ 09 · exec_command · 已返回 · 0.395 秒 · call_364b008bedd44d10b2a5b78d

▶ 10 · apply_patch · 已返回 · 0.783 秒 · call_47e4ad2867204977bc406ec7

▶ 11 · apply_patch · 已返回 · 0.889 秒 · call_0607641908fb4eff8dfb01bb

▶ 12 · exec_command · 未通过 · 0.198 秒 · call_e3715e0b5be94b90959a6e89

▶ 13 · exec_command · 未通过 · 0.394 秒 · call_98ea28a73c54435b98a95a9b

▶ 14 · apply_patch · 已返回 · 0.881 秒 · call_58ff17045eb44cfeb998cb95

▶ 15 · exec_command · 已返回 · 18.61 秒 · call_e46e010b797140ee850d847c

▶ 16 · exec_command · 已返回 · 0.897 秒 · call_4bb45edcbb58403c8a42cec1

▶ 17 · exec_command · 已返回 · 0.39 秒 · call_092f6806f17041a393c620f4

▶ 18 · apply_patch · 已返回 · 0.912 秒 · call_b99fb3346d5546038dcbcd66

▶ 19 · apply_patch · 已返回 · 1.067 秒 · call_2194c0ff062245098a005d8a

▶ 20 · apply_patch · 已返回 · 0.916 秒 · call_0210f1a6cfd2472cbf977b92

▶ 21 · exec_command · 已返回 · 18.251 秒 · call_55c0342ad95e4a4ebf9f207c

▶ 22 · exec_command · 已返回 · 0.66 秒 · call_3ae68b2a13d9407486e71cdb

▶ 23 · exec_command · 已返回 · 0.811 秒 · call_0330ff02c38f47b49b068f2e

▶ 24 · view_image · 已返回 · 0.546 秒 · call_3eae4811ec93408a8e80d06a

▶ 25 · exec_command · 已返回 · 0.436 秒 · call_177399d3381340a3a217c954

三体任务·同会话续作 · 运行完成 · 6 次

▶ 01 · exec_command · 已返回 · 29.122 秒 · call_02c1d00e344c4c6e8822b5d2

▶ 02 · apply_patch · 已返回 · 0.677 秒 · call_70f142eaa6e74736a5c0fb73

▶ 03 · exec_command · 已返回 · 13.908 秒 · call_1705e78bb6794cb7999a0eda

▶ 04 · apply_patch · 已返回 · 0.896 秒 · call_57a42e68f8324f9a89d41e1c

▶ 05 · exec_command · 未通过 · 11.642 秒 · call_130c30d256834ff6ad2fd436

▶ 06 · exec_command · 已返回 · 0.187 秒 · call_6adb2aa02ba843ee8d5a7fec

三体任务·视觉最终修订 · 运行完成 · 4 次

▶ 01 · exec_command · 已返回 · 0.266 秒 · call_0ea65be9f4b74440a39d9601

▶ 02 · apply_patch · 已返回 · 0.237 秒 · call_32768cadcab440c4ab7e8913

▶ 03 · apply_patch · 已返回 · 0.931 秒 · call_483914ed71b64cfa8d96dfad

▶ 04 · exec_command · 已返回 · 1.663 秒 · call_613ef27538a84ad9939d5371

三体任务·收敛说明文案更正（第4轮） · 运行完成 · 1 次

▶ 01 · exec_command · 已返回 · 0.374 秒 · call_8cbddc3c6bec4d5eafd467c0

三体任务·静态图最终排版 · 运行完成 · 5 次

▶ 01 · exec_command · 未通过 · 1.403 秒 · call_a719f03369504e40922edc03

▶ 02 · exec_command · 未通过 · 1.363 秒 · call_b457ae20469446d09f7e0cf9

▶ 03 · exec_command · 未通过 · 1.268 秒 · call_cce07aa85c8e4be6b89d2c39

▶ 04 · exec_command · 未通过 · 2.638 秒 · call_a7da351bb1c747128192d9d5

▶ 05 · exec_command · 已返回 · 2.017 秒 · call_9fd0537e19cb4f97826c9afc

工厂报表·首轮 · 未通过 · 23 次

▶ 01 · exec_command · 已返回 · 1.821 秒 · call_f010b1b390704b9d86a7d2ee

▶ 02 · exec_command · 已返回 · 1.332 秒 · call_1d56185b20164a6fbff5a76c

▶ 03 · exec_command · 未通过 · 3.621 秒 · call_35ea49e7af644b4a827a279a

▶ 04 · exec_command · 已返回 · 0.836 秒 · call_9f13303ea8d74cc59ac53ef9

▶ 05 · exec_command · 已返回 · 0.212 秒 · call_14a6e6f9a78f4e5990256688

▶ 06 · exec_command · 已返回 · 0.806 秒 · call_6a365e92583644db96085529

▶ 07 · write_stdin · 未通过 · 0.042 秒 · call_43c7e83b778544439c659aa1

▶ 08 · apply_patch · 未通过 · 0.067 秒 · call_9bf63795539f42eeb61ef51b

▶ 09 · apply_patch · 已返回 · 0.65 秒 · call_cb14714274c848ac8310422c

▶ 10 · exec_command · 已返回 · 0.136 秒 · call_e8a058edb10e4172b5b80784

▶ 11 · apply_patch · 已返回 · 0.967 秒 · call_e853a581ff2c49bfb6a2d1b3

▶ 12 · apply_patch · 已返回 · 0.979 秒 · call_581da84cd9c94ddc8bf28322

▶ 13 · apply_patch · 已返回 · 1.42 秒 · call_f84bf4ba2d594676a979718f

▶ 14 · exec_command · 已返回 · 1.203 秒 · call_376d6939ea2146cca6441b15

▶ 15 · exec_command · 已返回 · 0.471 秒 · call_39305f3d1e61484d979da1c3

▶ 16 · exec_command · 已返回 · 0.988 秒 · call_a988de18ee454d59ae07def1

▶ 17 · apply_patch · 未通过 · 0.142 秒 · call_6ce69dd4eff24704972ecd96

▶ 18 · exec_command · 已返回 · 0.23 秒 · call_b38297e1c9484655b0527feb

▶ 19 · exec_command · 已返回 · 0.381 秒 · call_0ea87b0f52af456488b1de13

▶ 20 · exec_command · 已返回 · 1.01 秒 · call_4b6c49d36e50419c804a0ab7

▶ 21 · exec_command · 已返回 · 0.475 秒 · call_7187eb27982f47ae85b660e2

▶ 22 · exec_command · 已返回 · 0.239 秒 · call_5fcfa0d7cbc0412eb3da0931

▶ 23 · exec_command · 已返回 · 0.314 秒 · call_1e9f46c4d64541ee9b6f39a3

工厂报表·同会话恢复 · 运行完成 · 4 次

▶ 01 · exec_command · 已返回 · 2.949 秒 · call_19cd3ae060d74f599fd85000

▶ 02 · exec_command · 已返回 · 0.429 秒 · call_627fe31c74df455eb5336ed5

▶ 03 · exec_command · 已返回 · 0.407 秒 · call_180fb59c0b5148518b9149c5

▶ 04 · exec_command · 已返回 · 0.291 秒 · call_409f808c70664ad6964b8f9f

真实诊断·压缩状态与补丁恢复 · 运行完成 · 3 次

▶ 01 · apply_patch · 未通过 · 0.08 秒 · call_a87f2ad7b84444b0afce5e0c

▶ **02 · apply_patch ·** 已返回 **· 0.781 秒 ·** `call_44428e541818443ea8c25367`

▶ **03 · exec_command ·** 已返回 **· 0.187 秒 ·** `call_e1aed6eb05b4438aa45b5284`

剩余边界与证据清单

本次未观察到真实 compaction，故压缩后语义保真仍未验证；不以普通续聊事实保留代替。离线 HTML 验证通过断网浏览器 context + setContent 完成；受管理浏览器禁止 file://，未宣称 file:// 导航已测。

所有生成数据均为合成验收资料。auth-state、Cookie、密钥、完整私有推理和压缩密文不进入报告。仍在写入或缺少终态的证据保持 pending；本报告不创建归档包。

旧controls-only应用内交互结果不能证明画布正确；最终以新增production-final尺寸、RGB像素与交互强验收为准。旧canvas-timing失败保留用于前后对照。

工厂 iframe 未授予 allow-downloads，因此 iframe 内导出 CSV 被隔离策略限制；未修改原始 HTML 离线导出已通过，真实应用的文件下载按钮也已验证内容一致。

三体首轮 4 个失败调用涉及模型补丁输入/命令错误；其中 time 后接 tail 掩盖退出码属于模型管道写法问题。已确认的应用缺陷是原生 apply_patch 异常状态丢失，而原生 shell code 2 的界面已有失败显示。

收敛续轮的 KeyError 发生在已生成 convergence.json 之后的结果打印诊断；独立51项核验与哈希检查证明数据正确。模型最终文字存在差值对象误标，已由第4轮纠正且数值未变。

工厂首轮具体 ModelBehaviorError 触发原因未充分记录，本报告不将其归因于 HMR 或某一已修复预览缺陷。

第5轮静态图排版再次暴露模型执行可靠性限制：CONV路径类型与Bbox接口使用错误产生Python Traceback，但tee管道退出0掩盖前段失败。运行指令已明确pipefail，本轮模型仍未遵循。报告依独立逐调用审计记录语义失败和恢复，不新增前端输出字符串猜错规则，也不把工具返回0当业务正确。

测试工具自身问题单独记录：重载验证最初误请求/api/health得到404，已按真实路由/health修正；云策略拒绝读取/proc/<pid>/cwd后改用已知QA进程命令行核对。两者均非产品缺陷，不计入产品失败。

▶ **展开本次使用的结构化来源**

由 build_final_report.py 从已有证据重新生成。HTML 自包含，无外部字体、脚本或资源；Markdown 与 results.json 提供文本和机器可读审计。生成时间：2026-11-04 09:47:11 UTC+8